Curso de Férias em Bioinformática

Uso de Biopython aplicado à genômica, transcriptômica e proteômica

Milenna Machado Pirovani

João Vítor Fernandes Dias

Belo Horizonte - MG
2026

Dia 1

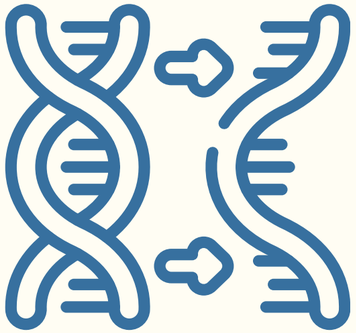

- Bio.Seq
- Bio.Align

Dia 2

- Bio.PDB

OPEN BIOINFORMATICS FOUNDATION

biopython

- Conjunto de ferramentas gratuitas para computação biológica;
- O pacote Biopython é um *software* de código aberto;
- Bio"Projects":

BioJava

moby

BioPerl

BioSQL

Bio php

Instalação

```
pip install biopython
pip install --upgrade biopython
pip uninstall biopython
```

NumPy

- ReportLab;
- matplotlib;
- networkx;
- rdflib;
- psycopg2;

*

```
import Bio
print(Bio.__version__)
```

Sequências: Objeto Seq

- Seq → Sequência → String;

- Quando usar?
    - Quando tiver sequências sem metadados

```
from Bio.Seq import Seq
```

Seq Avançado

- Sequência com conteúdo desconhecido:
  - O conteúdo NÃO pode ser acessado nem exibido;
  - Essa sequência existe como região anotada no genoma, mas o conteúdo real ainda não foi sequenciado;
  - Genomas de referência incompletos

Seq Avançado

- Sequência parcialmente definida:

Caso	Pode usar print() direto?	Por quê
Trecho 100% conhecido	Sim	Letras existem
Trecho 100% desconhecido	Não	Não há bases definidas
Trecho parcialmente conhecido	Não	Parte da sequência é indefinida

- Genomas incompletos
- Regiões não sequenciadas
- Montagens fragmentadas (scaffolds com Ns)

  - Bases que biologicamente não existem nos dados.

Seq Avançado

- Concatenando com regiões desconhecidas

Operação	**Funciona?**	**Por quê**
Concatenação	Sim	O comprimento é conhecido
len()	Sim	Tamanho existe
print()	Não	Conteúdo parcial não pode virar string
Acessar só partes conhecidas	Sim	Bases reais existem
Acessar partes indefinidas	Não	Não há letras ali

Seq Record

É um objeto que contém:

- Sequência
- Nome
- O que ela é
- De onde veio
- O que existe dentro dela (genes, domínios, CDS...)
- Ligações com outros bancos de dados

Seq Record

Parte	O que representa
.seq	A sequência
.id	Identificador único
.name	Nome curto
.description	Descrição
.annotations	Metadados gerais
.letter_annotations	Info por base
.features	Genes/domínios/etc
.dbxrefs	Links externos

```
from Bio.SeqRecord import SeqRecord
```

Arquivo FASTA

Cabeçalho

Identificador

Descrição livre

```
>gi|45478711|ref|NC_005816.1| Yersinia pestis biovar Microtus str. 91001 plasmid pPCP1, complete
sequence
TGTAACGAACGGTGCAATAGTGATCCACACCCAACGCCTGAAATCAGATCCAGGGGGTAATCTGCTCTCC
TGATTCAGGAGAGTTTATGGTCACTTTTGAGACAGTTATGGAAATTAAAATCCTGCACAAGCAGGGAATG
AGTAGCCGGGCGATTGCCAGAGAACTGGGGATCTCCCGCAATACCGTTAAACGTTATTTGCAGGCAAAAT
CTGAGCCGCCAAAATATACGCCGCGACCTGCTGTTGCTTCACTCCTGGATGAATACCGGGATTATATTCG
TCAACGCATCGCCGATGCTCATCCTTACAAAATCCCGGCAACGGTAATCGCTCGCGAGATCAGAGACCAG
GGATATCGTGGCGGAATGACCATTCTCAGGGCATTCATTCGTTCTCTCTCGGTTCCTCAGGAGCAGGAGC
CTGCCGTTCGGTTCGAAACTGAACCCGGACGACAGATGCAGGTTGACTGGGGCACTATGCGTAATGGTCG
CTCACCGCTTCACGTGTTCGTTGCTGTTCTCGGATACAGCCGAATGCTGTACATCGAATTCACTGACAAT
ATGCGTTATGACACGCTGGAGACCTGCCATCGTAATGCGTTCCGCTTCTTTGGTGGTGTGCCGCGCGAAG
TGTTGTATGACAATATGAAAACTGTGGTTCTGCAACGTGACGCATATCAGACCGGTCAGCACCGGTTCCA
TCCTTCGCTGTGGCAGTTCGGCAAGGAGATGGGCTTCTCTCCCCGACTGTGTCGCCCCTTCAGGGCACAG
ACTAAAGGTAAGGTGGAACGGATGGTGCAGTACACCCGTAACAGTTTTTACATCCCACTAATGACTCGCC
TGCGCCCGATGGGGATCACTGTCGATGTTGAAACAGCCAACCGCCACGGTCTGCGCTGGCTGCACGATGT
CGCTAACCAACGAAAGCATGAAACAATCCAGGCCCGTCCCTGCGATCGCTGGCTCGAAGAGCAGCAGTCC
ATGCTGGCACTGCCTCCGGAGAAAAAAGAGTATGACGTGCATCTTGATGAAAATCTGGTGAACTTCGACA
AACACCCCCTGCATCATCCACTCTCCATCTACGACTCATTCTGCAGAGGAGTGGCGTGATGATGGAACTG
CAACATCAACGACTGATGGCGCTCGCCGGGCAGTTGCAACTGGAAAGCCTTATAAGCGCAGCGCCTGCGC
TGTCACAACAGGCAGTAGACCAGGAATGGAGTTATATGGACTTCCTGGAGCATCTGCTTCATGAAGAAAA
ACTGGCACGTCATCAACGTAAACAGGCGATGTATACCCGAATGGCAGCCTTCCCGGCGGTGAAAACGTTC
GAAGAGTATGACTTCACATTCGCCACCGGAGCACCGCAGAAGCAACTCCAGTCGTTACGCTCACTCAGCT
TCATAGAACGTAATGAAAATATCGTATTACTGGGGCCATCAGGTGTGGGGAAAACCCATCTGGCAATAGC
GATGGGCTATGAAGCAGTCCGTGCAGGTATCAAAGTTCGCTTCACAACAGCAGCAGATCTGTTACTTCAG
TTATCTACGGCACAACGTCAGGGCCGTTATAAAACGACGCTTCAGCGTGGAGTAATGGCCCCCCGCCTGC
TCATCATTGATGAAATAGGCTATCTGCCGTTCAGTCAGGAAGAAGCAAAGCTGTTCTTCCAGGTCATCGC
TAAACGTTACGAAAAGAGCGCAATGATCCTGACATCCAATCTGCCGTTCGGGCAGTGGGATCAAACGTTC
```

Sequência

Limitações

- O formato do arquivo limita o que o SeqRecord pode conter

```
from Bio import SeqIO
```

https://raw.githubusercontent.com/biopython/biopython/master/Tests/GenBank/NC_005816.fna

Arquivo GenBank

```
LOCUS       NC_005816               9609 bp    DNA     circular BCT 21-JUL-2008
DEFINITION  Yersinia pestis biovar Microtus str. 91001 plasmid pPCP1, complete
            sequence.
ACCESSION   NC_005816
VERSION     NC_005816.1  GI:45478711
DBLINK      Project: 58037
KEYWORDS    .
SOURCE      Yersinia pestis biovar Microtus str. 91001
  ORGANISM  Yersinia pestis biovar Microtus str. 91001
            Bacteria; Proteobacteria; Gammaproteobacteria; Enterobacteriales;
            Enterobacteriaceae; Yersinia.
REFERENCE   1  (bases 1 to 9609)
  AUTHORS   Zhou,D., Tong,Z., Song,Y., Han,Y., Pei,D., Pang,X., Zhai,J., Li,M.,
            Cui,B., Qi,Z., Jin,L., Dai,R., Du,Z., Wang,J., Guo,Z., Wang,J.,
            Huang,P. and Yang,R.
  TITLE     Genetics of metabolic variations between Yersinia pestis biovars
            and the proposal of a new biovar, microtus
  JOURNAL   J. Bacteriol. 186 (15), 5147-5152 (2004)
   PUBMED   15262951
REFERENCE   2  (bases 1 to 9609)
  AUTHORS   Song,Y., Tong,Z., Wang,J., Wang,L., Guo,Z., Han,Y., Zhang,J.,
            Pei,D., Zhou,D., Qin,H., Pang,X., Han,Y., Zhai,J., Li,M., Cui,B.,
            Qi,Z., Jin,L., Dai,R., Chen,F., Li,S., Ye,C., Du,Z., Lin,W.,
            Wang,J., Yu,J., Yang,H., Wang,J., Huang,P. and Yang,R.
  TITLE     Complete genome sequence of Yersinia pestis strain 91001, an
            isolate avirulent to humans
  JOURNAL   DNA Res. 11 (3), 179-197 (2004)
   PUBMED   15368893
REFERENCE   3  (bases 1 to 9609)
  CONSRTM   NCBI Genome Project
  TITLE     Direct Submission
  JOURNAL   Submitted (16-MAR-2004) National Center for Biotechnology
            Information, NIH, Bethesda, MD 20894, USA
REFERENCE   4  (bases 1 to 9609)
  AUTHORS   Song,Y., Tong,Z., Wang,L., Han,Y., Zhang,J., Pei,D., Wang,J.,
            Zhou,D., Han,Y., Pang,X., Zhai,J.  Chen,F., Qin,H., Wang,J.  Li,S.,
            Guo,Z., Ye,C., Du,Z., Lin,W., Wang,J., Yu,J., Yang,H., Wang,J.,
            Huang,P. and Yang,R.
  TITLE     Direct Submission
  JOURNAL   Submitted (24-APR-2003) The Institute of Microbiology and
            Epidemiology, Academy of Military Medical Sciences, No. 20,
            Dongdajie Street, Fengtai District, Beijing 100071, People's
            Republic of China
COMMENT     PROVISIONAL REFSEQ: This record has not yet been subject to final
            NCBI review. The reference sequence was derived from AE017046.
            COMPLETENESS: full length.
```

https://raw.githubusercontent.com/biopython/biopython/master/Tests/GenBank/NC_005816.gb

Seq Feature

Regiões específicas, como:

- Genes;
- CDS;
- Sítios de ligação ou repetições;
- Localização, tipo e qualificadores

```
from Bio.SeqFeature import CompoundLocation, SimpleLocation
```

SeqIO

- Leitura e escrita de sequências;

- Principal função:
  - SeqIO.parse()

SeqIO.parse

- Lê o arquivo e entrega cada sequência, uma por vez
- Retorna vários Seq.Records

SeqIO.read

- Lê o arquivo e entrega a única sequência que existe nele.
- Retorna um único Seq.Record

```
from Bio import SeqIO
```

SeqIO.to_dict()

Vantagens:

Você ganha um dicionário de verdade com objetos SeqRecord completos na RAM. Pode:

- Editar sequências
- Mudar descrições
- Remover registros
- Adicionar novos

SeqIO.to_dict()

Vantagens:

Você ganha um dicionário de verdade com objetos SeqRecord completos na RAM. Pode:

- Editar sequências
- Mudar descrições
- Remover registros
- Adicionar novos

Desvantagens:

Ele carrega todas as sequências na memória. Se o arquivo tiver:

- 100 sequências → tranquilo
- 100 mil → começa a pesar
- 10 milhões → vai travar

SeqIO.to_dict()

Vantagens:

Você ganha um dicionário de verdade com objetos SeqRecord completos na RAM. Pode:

- Editar sequências
- Mudar descrições
- Remover registros
- Adicionar novos

Desvantagens:

Ele carrega todas as sequências na memória. Se o arquivo tiver:

- 100 sequências → tranquilo
- 100 mil → começa a pesar
- 10 milhões → vai travar

QUANDO USAR? Você precisa modificar os registros.

SeqIO.index()

Vantagens:

- Usa pouca memória
- Rápido para acessar registros individuais
- Não precisa reler tudo toda vez

SeqIO.index()

Vantagens:

- Usa pouca memória
- Rápido para acessar registros individuais
- Não precisa reler tudo toda vez

Desvantagens:

- Você não pode alterar os registros
- Só leitura

SeqIO.index()

Vantagens:

- Usa pouca memória
- Rápido para acessar registros individuais
- Não precisa reler tudo toda vez

Desvantagens:

- Você não pode alterar os registros
- Só leitura

QUANDO USAR? Você quer consultar sequências grandes

SeqIO.index_db()

Vantagens:

- Usa pouquíssima memória
- Pode reutilizar o índice depois
- Ideal para milhões de sequências

SeqIO.index_db()

Vantagens:

- Usa pouquíssima memória
- Pode reutilizar o índice depois
- Ideal para milhões de sequências

Desvantagens:

- Leva mais tempo para criar o índice na primeira vez
- Gera um arquivo extra .db

SeqIO.index_db()

Vantagens:

- Usa pouquíssima memória
- Pode reutilizar o índice depois
- Ideal para milhões de sequências

Desvantagens:

- Leva mais tempo para criar o índice na primeira vez
- Gera um arquivo extra .db

QUANDO USAR? Você trabalha com dados gigantes ou vai rodar análises repetidas nos mesmos arquivos.

Bio.Align

- Bio.AlignIO lida com arquivos que contêm um ou mais alinhamentos de sequência representados como objetos Alignment;

- Um alinhamento de sequências é um conjunto de duas ou mais sequências organizadas de forma que:
  - Tenham o mesmo comprimento
  - Possam conter lacunas ("-")
  - Permitam comparar posições equivalentes

Bio.Align

Função:

- Identificar regiões conservadas
- Inferir função de proteínas
- Construir árvores filogenéticas
- Detectar mutações ou SNPs
- Comparar domínios estruturais

Tipo	Descrição
Global	Alinha sequências do início ao fim
Local	Alinha apenas trechos semelhantes
Múltiplo (MSA)	Alinha 3 ou mais sequências

```
from Bio import AlignIO
```

Bio.Align

property	description
`score`	Alignment score, or `None` if unknown
`substitution_score`	Total substitution score of letters aligned to each other, or `None` if unknown
`gap_score`	Total gap score, or `None` if unknown
`aligned`	The number of aligned letters in the alignment. This quantity is also calculate = `identities` + `mismatches`. If some sequences are undefined, then `aligned`
`identities`	Number of matched letters in the alignment
`mismatches`	Number of mismatched letters in the alignment
`positives`	Number of aligned letters with a positive substitution score
`gaps`	Total gap length
`open_gaps`	Number of gaps opened in the alignment
`extend_gaps`	Number of gap extensions in the alignment
`insertions`	Total number of letters inserted
`open_insertions`	Number of insertion gaps opened in the alignment
`extend_insertions`	Number of insertion gap extensions in the alignment
`deletions`	Total number of letters deleted
`open_deletions`	Number of deletion gaps opened in the alignment
`extend_deletions`	Number of deletion gap extensions in the alignment
`left_gaps`	Total gap length on the left side of the alignment
`open_left_gaps`	Number of gaps opened on the left side of the alignment
`extend_left_gaps`	Number of gap extensions on the left side of the alignment
`left_insertions`	Number of letters inserted on the left side of the alignment
`open_left_insertions`	Number of insertion gaps opened on the left side of the alignment
`extend_left_insertions`	Number of insertion gap extensions on the left side of the alignment
`left_deletions`	Number of characters deleted on the left side of the alignment
`open_left_deletions`	The number of deletion gaps opened on the left side of the alignment
`extend_left_deletions`	Number of deletion gap extensions on the left side of the alignment
`internal_gaps`	Total length of gaps within the alignment
`open_internal_gaps`	Number of gaps opened in the interior of the alignment
`extend_internal_gaps`	Number of gap extensions in the interior of the alignment
`internal_insertions`	Number of letters inserted in the interior of the alignment
`open_internal_insertions`	Number of insertion gaps opened in the interior of the alignment
`extend_internal_insertions`	Number of insertion gas extensions in the interior of the alignment
`internal_deletions`	Number of characters deleted from the alignment
`open_internal_deletions`	Number of deletion gaps opened in the interior of the alignment
`extend_internal_deletions`	Number of deletion gap extensions in the interior of the alignment
`right_gaps`	Total gap length on the right side of the alignment
`open_right_gaps`	Number of gaps opened on the right side of the alignment
`extend_right_gaps`	Number of gap extensions on the right side of the alignment
`right_insertions`	Number of letters inserted on the right side of the alignment
`open_right_insertions`	The number of insertion gaps opened on the right side of the alignment
`extend_right_insertions`	The number of insertion gap extensions on the right side of the alignment
`right_deletions`	Number of letters deleted on the right side of the alignment
`open_right_deletions`	Number of deletion gaps opened on the right side of the alignment
`extend_right_deletions`	Number of deletion gap extensions on the right side of the alignment

Formatos de Alinhamento

Alinhamentos que podem ser analisados no Bio.Align

File format `fmt`	Description	text / binary	Supported by `write`
`a2m`	A2M	text	yes
`bed`	Browser Extensible Data (BED)	text	yes
`bigbed`	bigBed	binary	yes
`bigmaf`	bigMaf	binary	yes
`bigpsl`	bigPsl	binary	yes
`chain`	UCSC chain file	text	yes
`clustal`	ClustalW	text	yes
`emboss`	EMBOSS	text	no
`exonerate`	Exonerate	text	yes
`fasta`	Aligned FASTA	text	yes
`hhr`	HH-suite output files	text	no
`maf`	Multiple Alignment Format (MAF)	text	yes
`mauve`	Mauve eXtended Multi-FastA (xmfa) format	text	yes
`msf`	GCG Multiple Sequence Format (MSF)	text	no
`nexus`	NEXUS	text	yes
`phylip`	PHYLIP output files	text	yes
`psl`	Pattern Space Layout (PSL)	text	yes
`sam`	Sequence Alignment/ Map (SAM)	text	yes
`stockholm`	Stockholm	text	yes
`tabular`	Tabular output from BLAST or FASTA	text	no

Bio.PDB

Estruturas 3D de macromoléculas

- Ler arquivos estruturais (.pdb ou .cif)
- Navegar na hierarquia estrutural
- Acessar coordenadas atômicas
- Manipular cadeias, resíduos e átomos

Formato PDB e mmCIF

Criado na década de 1970:

- Computadores tinham memória limitada
- Estruturas eram pequenas

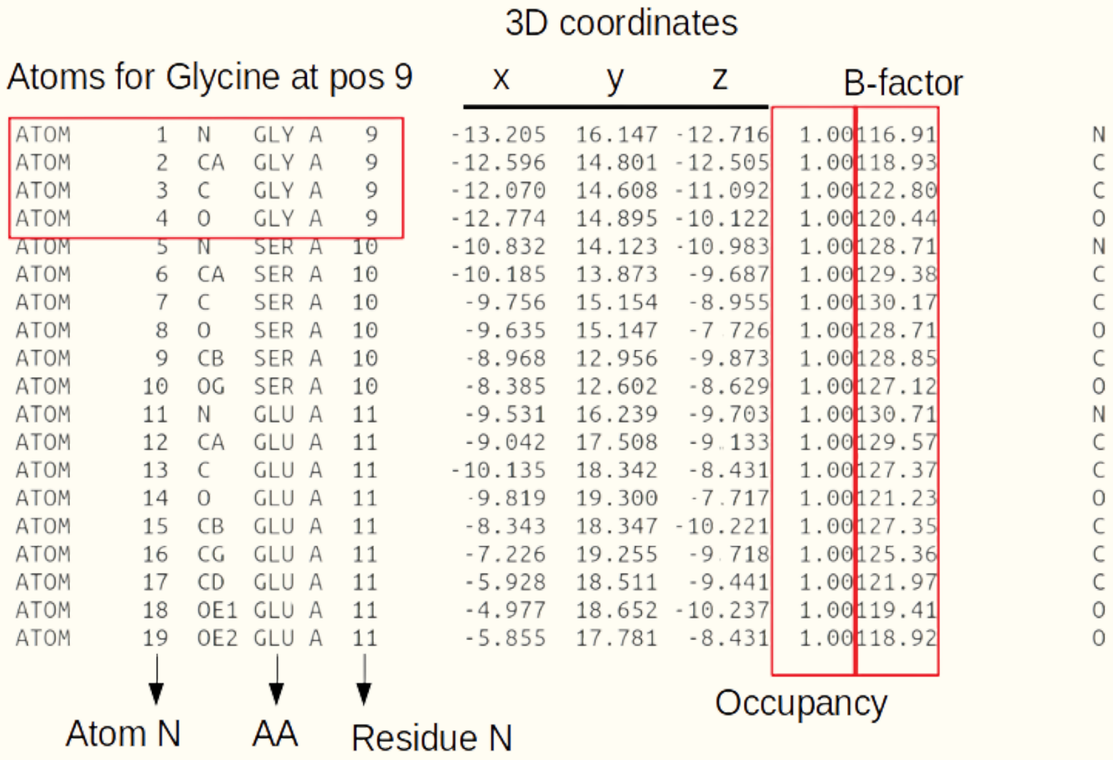

ATOM	1	N	GLY	A	9	-13.205	16.147	-12.716	1.00	116.91	N
ATOM	2	CA	GLY	A	9	-12.596	14.801	-12.505	1.00	118.93	C
ATOM	3	C	GLY	A	9	-12.070	14.608	-11.092	1.00	122.80	C
ATOM	4	O	GLY	A	9	-12.774	14.895	-10.122	1.00	120.44	O
ATOM	5	N	SER	A	10	-10.832	14.123	-10.983	1.00	128.71	N
ATOM	6	CA	SER	A	10	-10.185	13.873	-9.687	1.00	129.38	C
ATOM	7	C	SER	A	10	-9.756	15.154	-8.955	1.00	130.17	C
ATOM	8	O	SER	A	10	-9.635	15.147	-7.726	1.00	128.71	O
ATOM	9	CB	SER	A	10	-8.968	12.956	-9.873	1.00	128.85	C
ATOM	10	OG	SER	A	10	-8.385	12.602	-8.629	1.00	127.12	O
ATOM	11	N	GLU	A	11	-9.531	16.239	-9.703	1.00	130.71	N
ATOM	12	CA	GLU	A	11	-9.042	17.508	-9.133	1.00	129.57	C
ATOM	13	C	GLU	A	11	-10.135	18.342	-8.431	1.00	127.37	C
ATOM	14	O	GLU	A	11	-9.819	19.300	-7.717	1.00	121.23	O
ATOM	15	CB	GLU	A	11	-8.343	18.347	-10.221	1.00	127.35	C
ATOM	16	CG	GLU	A	11	-7.226	19.255	-9.718	1.00	125.36	C
ATOM	17	CD	GLU	A	11	-5.928	18.511	-9.441	1.00	121.97	C
ATOM	18	OE1	GLU	A	11	-4.977	18.652	-10.237	1.00	119.41	O
ATOM	19	OE2	GLU	A	11	-5.855	17.781	-8.431	1.00	118.92	O

.cif substituiu o antigo formato .pdb:

- Não tem limite de número de átomos
- Não tem limite de cadeias
- Usa estrutura chave-valor (tipo JSON científico)

```
from Bio.PDB.MMCIFParser import MMCIFParser
```

Leitura de outros formatos

BinaryCIF

```
from Bio.PDB.binary_cif import
BinaryCIFParserparser = BinaryCIFParser()
```

MMTF

```
from Bio.PDB.mmtf import MMTFParserstructure =
MMTFParser.get_structure("PDB/4CUP.mmtf")
```

PDB e PQR

```
from Bio.PDB.PDBParser import PDBParserparser =
PDBParser(PERMISSIVE=1)
```

PDBML (PDB XML)

```
from Bio.PDB.PDBMLParser import
PDBMLParserpdbml_parser = PDBMLParser()
```

SMCRA: A arquitetura da estrutura no Bio.PDB

```
Structure
  └──── Model
        └──── Chain
              └──── Residue
                    └──── Atom
```

Código da aula

Curso de Férias em Bioinformática

Uso de Biopython aplicado à genômica, transcriptômica e proteômica

Milenna Machado Pirovani

João Vítor Fernandes Dias

Belo Horizonte - MG
2026